

Στατιστική Ανάλυση Δεδομένων

Εφαρμογή στο 93CARS Data Set

Αλέξανδρος Τσίγγος (AEM: 205), email: atsingo@csd.auth.gr



ΑΡΙΣΤΟΤΕΛΕΙΟ
ΠΑΝΕΠΙΣΤΗΜΙΟ
ΘΕΣΣΑΛΟΝΙΚΗΣ

Περιεχόμενα

1 Περίληψη.....	3
2 Σύνολο Δεδομένων 93CARS	3
3 Προετοιμασία και καθαρισμός δεδομένων.....	4
4 Περιγραφική Στατιστική	6
Cluster 1: Identification & Classification	7
Cluster 2: Price Analysis.....	8
Cluster 3: Fuel Efficiency	10
Cluster 4: Engine & Powertrain	11
Cluster 5: Transmission & Drivetrain	12
Cluster 6: Safety Features	13
Cluster 7: Size & Dimensions.....	14
Cluster 8: Interior Space & Capacity	14
5 Στατιστική Συμπερασματολογία.....	15
Research Question 1.....	15
Research Question 2.....	16
Research Question 3.....	17
Research Question 4.....	18
Research Question 5.....	19
Research Question 6.....	20
6 Ανάλυση Παλινδρόμησης	22
6.1 Παλινδρόμηση στην Ελάχιστη Τιμή Οχήματος.....	22
6.2 Παλινδρόμηση στην Κατανάλωση των οχημάτων στην πόλη.....	25
7 Αναφορές.....	27

1 Περίληψη

Η παρούσα εργασία πραγματεύεται τη στατιστική ανάλυση του συνόλου δεδομένων "93CARS", το οποίο αφορά τα χαρακτηριστικά επιβατικών οχημάτων που κυκλοφόρησαν στην αγορά των ΗΠΑ το 1993. Στόχος της μελέτης είναι η εξαγωγή συμπερασμάτων σχετικά με τις τιμολογιακές πολιτικές, την αποδοτικότητα καυσίμου και τις προδιαγραφές ασφαλείας της εποχής, μέσω της χρήσης της γλώσσας προγραμματισμού R. Η μεθοδολογία οργανώθηκε σε τρεις φάσεις: Αρχικά, πραγματοποιήθηκε προεπεξεργασία και καθαρισμός των δεδομένων (Data Cleaning) για τη διαχείριση ελλειπουσών τιμών και τυπογραφικών λαθών. Στη συνέχεια, διενεργήθηκε Περιγραφική Στατιστική με έμφαση στην Μονομεταβλητή Ανάλυση (Univariate Analysis) και έπειτα προχωρήσαμε στην Στατιστική Συμπερασματολογία και Διμεταβλητή ανάλυση (Bivariate Analysis), όπου εφαρμόστηκαν έλεγχοι υποθέσεων (t-tests, ANOVA, Chi-Square) και αναλύθηκαν συσχετίσεις. Τέλος, αναπτύχθηκαν μοντέλα Παλινδρόμησης (Regression Analysis) για την πρόβλεψη της ελάχιστης τιμής και της κατανάλωσης καυσίμου σε αστικές συνθήκες. Τα αποτελέσματα ανέδειξαν ότι το βάρος και η υποδύναμη αποτελούν τους κυριότερους προσδιοριστικούς παράγοντες της τιμής, ενώ η κατανάλωση καυσίμου εντός πόλης (CityMPG) περιγράφεται βέλτιστα μέσω μοντέλων αρνητικής διωνυμικής κατανομής, με το βάρος του οχήματος να παίζει κυρίαρχο ρόλο. Επιπλέον, διαπιστώθηκε ισχυρή θετική συσχέτιση μεταξύ του επιπέδου ασφαλείας (αερόσακοι) και της τιμής πώλησης, ενώ δεν παρατηρήθηκαν στατιστικά σημαντικές διαφορές στις τιμές μεταξύ εγχώριων (ΗΠΑ) και εισαγόμενων κατασκευαστών.

2 Σύνολο Δεδομένων 93CARS

Στο πλαίσιο της εργασίας του μαθήματος «Στατιστική Ανάλυση Δεδομένων» αξιοποιήθηκε το σύνολο δεδομένων "93CARS dataset". Το αρχείο δεδομένων που αξιοποιήθηκε έχει τα δεδομένα με τις ονομασίες των κατηγοριών - labels αποθηκευμένα σε μορφή csv ("93Cars_labels.csv"). Αυτό περιλαμβάνει στοιχεία για 93 νέα μοντέλα αυτοκινήτων από το έτος κατασκευής 1993. Αν θεωρήσουμε ότι ο πληθυσμός (population) αποτελείται από όλα τα επιβατικά αυτοκίνητα και τα βανάκια που διατίθονταν στην αγορά των ΗΠΑ με χρονολογία μοντέλου το 1993, τότε το σύνολο δεδομένων που χρησιμοποιήθηκε για την ανάλυση αυτή αντιπροσωπεύει ένα δείγμα (sample) αυτού του πληθυσμού. Το μέγεθος του δείγματος αυτού είναι $n=93$, δηλαδή έχουμε 93 πειραματικές μονάδες. Κάθε πειραματική μονάδα αντιπροσωπεύει ένα συγκεκριμένο μοντέλο αυτοκινήτου (π.χ. Honda Civic, Chevrolet Cavalier) και χαρακτηρίζεται από 27 χαρακτηριστικά ή αλλιώς τυχαίες μεταβλητές [1].

Οι μεταβλητές που έχουμε κατηγοριοποιούνται σε Ποσοτικές και Κατηγορικές μεταβλητές ως εξής:

A. Κατηγορικές Μεταβλητές

a. Ονομαστικές Μεταβλητές:

- i. Manufacturer (π.χ., Chevrolet, Audi).
- ii. Model (π.χ., Caprice, 90).
- iii. Type: Με κατηγορίες Small, Sporty, Compact, Midsize, Large, και Van.
- iv. DriveTrain: Περιλαμβάνει τους τρεις δυνατούς τρόπους μετάδοσης της κίνησης στους τροχούς (Front-wheel, Rear-wheel, or All-wheel).
- v. ManualTrans: Δυαδική κατηγορική μεταβλητή. Όταν λαμβάνει την τιμή ένα τότε αυτό υποδεικνύει την διαθεσιμότητα χειροκίνητου

κιβώτιου ταχυτήτων για αυτό το μοντέλο. Αντίθετα, αν λάβει την τιμή μηδέν τότε το όχημα αυτό βγαίνει μόνο με έκδοση αυτόματου κιβωτίου ταχυτήτων.

- vi. Domestic: Δυαδική κατηγορική μεταβλητή, με το ένα να σηματοδοτεί ότι ο κατασκευαστής του οχήματος είναι από τις ΗΠΑ και το μηδέν να σηματοδοτεί το αντίθετο.

b. Διατακτικές Μεταβλητές:

- i. AirBags: Περιλαμβάνει μια ιεράρχηση του βασικού εξοπλισμού ασφαλείας (αερόσακοι) του οχήματος (0= None, 1= driver only, 2= driver & passenger).

B. Ποσοτικές Μεταβλητές

a. Συνεχείς Μεταβλητές:

- i. Price Variables: MinimumPrice, MaximumPrice, και MidrangePrice (υπολογίζεται ως ο Μέσος όρος του min και του max price).
- ii. TotalAvgMPG: Ο μέσος όρος κατανάλωσης του οχήματος εντός και εκτός πόλης. Λαμβάνει θετικές πραγματικές τιμές.
- iii. EngineSize: Κυβισμός σε λίτρα.
- iv. FuelTankCapacity: Χωρητικότητα δεξαμενής καυσίμων σε gallons.
- v. Rear_seat: Χώρος στα πίσω καθίσματα σε inches.

b. Διακριτές Μεταβλητές:

- i. CityMPG: Πόσα μίλια βγάζει ένα όχημα μέσα στην πόλη ανά γαλόνι.
- ii. HighwayMPG: Πόσα μίλια βγάζει ένα όχημα εκτός πόλης ανά γαλόνι.
- iii. NumberOfCylinders: Αριθμός κυλίνδρων.
- iv. Horsepower: Μέγιστη ιπποδύναμη.
- v. RPM: Στροφές του κινητήρα ανά λεπτό στην μέγιστη ιπποδύναμη.
- vi. ERM: Στροφές κινητήρα ανά μίλι στην υψηλότερη ταχύτητα.
- vii. Length: Το μήκος του οχήματος σε Inches.
- viii. Width: Το πλάτος του οχήματος σε Inches.
- ix. WheelBase: Η απόσταση μεταξύ των τροχών σε inches.
- x. U_turn: Ο χώρος σε feet που χρειάζεται το όχημα για να κάνει αναστροφή (U turn).
- xi. Passengers: Χωρητικότητα ατόμων.
- xii. LuggageCapa: Χωρητικότητα αποσκευών σε cu. ft.
- xiii. Weight: Το βάρος του οχήματος σε pounds.

Το σύνολο δεδομένων είναι σε μεγάλο βαθμό πλήρες, με ελάχιστες ελλείπουσες τιμές (missing values) που περιορίζονται σε συγκεκριμένες λογικές εξαιρέσεις, όπως:

- Κύλινδροι (NumberOfCylinders): Ελλείπουσα τιμή για το Mazda RX-7 λόγω του σχεδιασμού του περιστροφικού κινητήρα που δεν έχει κυλίνδρους.
- Χώρος στο πίσω κάθισμα (Rear_seat): Ελλείπουσα τιμή για τα διαθέσιμα σπορ αυτοκίνητα (Corvette και RX-7).
- Χωρητικότητα αποσκευών: Ελλείπουσα τιμή για τα βανάκια και τα διαθέσιμα αυτοκίνητα.

3 Προετοιμασία και καθαρισμός δεδομένων

Στο αρχείο “01_Data_Preparation.R” περιλαμβάνεται ο κώδικας που υλοποιεί την προετοιμασία και τον καθαρισμό των δεδομένων.


Το **πρώτο βήμα** αφορούσε τη φόρτωση των αρχικών δεδομένων στο περιβάλλον της R, ορίζοντας τις κατάλληλες παραμέτρους για τον διαχωρισμό των πεδίων και των δεκαδικών ψηφίων. Κατά τη φόρτωση, έγινε αυτόματη αναγνώριση των μεταβλητών κειμένου ως κατηγορικών (factors).

Στη συνέχεια, προχωρήσαμε σε **διορθώσεις ορθογραφικών σφαλμάτων** και τυποποίηση ετικετών:

- Στη μεταβλητή Manufacturer, διορθώθηκαν τυπογραφικά λάθη που θα επηρέαζαν την ομαδοποίηση, όπως η αλλαγή του “Chrylser” σε “Chrysler” και του “Mercedes-Be” σε “Mercedes-Benz”.
- Στη μεταβλητή Type, τυποποιήθηκαν οι ετικέτες που εμφανίζονταν αποκομμένες, διορθώνοντας το “Compac” σε “Compact” και το “Midsiz” σε “Midsize”.

Ακολούθως, αντιμετωπίστηκαν οι **ελλείπουσες τιμές (Missing Values)** και οι δομικές ανωμαλίες:

1. **Συμπλήρωση Τιμών (Imputation):** Για την έλλειψη στην HighwayMPG (παρατήρηση 55), πραγματοποιήθηκε πρόβλεψη της τιμής μέσω απλής γραμμικής παλινδρόμησης (lm), αξιοποιώντας την ισχυρή συσχέτιση με τη μεταβλητή CityMPG. Πριν την εφαρμογή του μοντέλου, ελέγχθηκε και επιβεβαιώθηκε ότι ικανοποιούνται οι βασικές στατιστικές υποθέσεις, και συγκεκριμένα η **ομοσκεδαστικότητα (homoscedasticity)** και η **κανονικότητα των καταλοίπων (normality of residuals)**.



Εικόνα 0.1 Έλεγχος ομοσκεδαστικότητας και κανονικότητας υπολοίπων για το imputation lm.

2. **Χειρισμός Δομικής Ανωμαλίας (Structural Anomaly) - NumberOfCylinders:** Εντοπίστηκε η ειδική περίπτωση του **Mazda RX-7** (παρατήρηση 57), το οποίο διαθέτει περιστροφικό κινητήρα Wankel (Rotary engine) και όχι συμβατικά έμβολα με αποτέλεσμα να έχει missing value λόγω της μη ύπαρξης κυλίνδρων στο όχημα. Η αντιμετώπιση της μεταβλητής ως αριθμητικής θα ήταν λανθασμένη για τους εξής λόγους:

- Η εισαγωγή του μέσου όρου ή της επικρατούσας τιμής (mode) θα εισήγαγε φυσικό σφάλμα (physical error), αλλοιώνοντας τα χαρακτηριστικά του οχήματος.
- Η καταχώριση της τιμής 0, αν και μηχανικά ορθή, θα δημιουργούσε στατιστικό πρόβλημα, καθώς ενώ γενικά υπάρχει ισχυρά θετική συσχέτιση μεταξύ των μεταβλητών NumberOfCylinders και Horsepower, το RX-7, με πολύ μεγάλη ιπποδύναμη (255 HP) καταστρέφει αυτή τη γραμμική συσχέτιση. Για τον λόγο αυτό, η μεταβλητή μετατράπηκε σε **Factor (Κατηγορική)** και ανατέθηκε ρητά το επίπεδο **"rotary"** στη συγκεκριμένη παρατήρηση. Αυτή η προσέγγιση επιτρέπει στον περιστροφικό κινητήρα να έχει τον δικό του μοναδικό συντελεστή (coefficient), διαχωρίζοντάς τον από την αριθμητική τάση των εμβολοφόρων κινητήρων.

Τέλος, έγινε **λογική συμπλήρωση** (logical imputation) στις μεταβλητές χωρητικότητας:

- Στα πεδία Rear_seat και LuggageCapa, οι τιμές ορίστηκαν σε 0 για τα διαθέσια σπορ αυτοκίνητα (π.χ. Corvette, RX-7).
- Για τα οχήματα τύπου Van, η ελλείπουσα τιμή στον χώρο αποσκευών (LuggageCapa) αντικαταστάθηκε με τον μέσο όρο των οχημάτων της κατηγορίας "Large".

Το καθαρισμένο σύνολο δεδομένων αποθηκεύτηκε σε νέο αρχείο (cleaned_93Cars.csv) και στα επόμενα βήματα της ανάλυσης φορτώναμε κατευθείαν αυτό.

```
> str(cars_data)
'data.frame': 93 obs. of 27 variables:
 $ Manufacturer : Factor w/ 31 levels "Acura","Audi",...: 1 1 2 2 3 4 4 4 4 5 ...
 $ Model        : Factor w/ 93 levels "100","190E","240",...: 49 54 9 1 6 24 56 73 72 35 ...
 $ Type         : Factor w/ 6 levels "Compact","Large",...: 4 3 1 3 3 3 2 2 3 2 ...
 $ MinimumPrice : num 12.9 29.2 25.9 30.8 23.7 14.2 19.9 22.6 26.3 33 ...
 $ MidrangePrice: num 15.9 33.9 29.1 37.7 30 15.7 20.8 23.7 26.3 34.7 ...
 $ MaximumPrice : num 18.8 38.7 32.3 44.6 36.2 17.3 21.7 24.9 26.3 36.3 ...
 $ CityMPG      : int 25 18 20 19 22 22 19 16 19 16 ...
 $ HighwayMPG   : int 31 25 26 26 30 31 28 25 27 25 ...
 $ AirBags      : Ord.factor w/ 3 levels "none"<"driver only"<...: 1 3 2 3 2 2 2 2 2 2 ...
 $ DriveTrainType: Factor w/ 3 levels "all wheel drive",...: 2 2 2 2 3 2 2 3 2 2 ...
 $ NumberOfCylinders: Factor w/ 6 levels "3","4","5","6",...: 2 4 4 4 2 2 4 4 5 ...
 $ EngineSize   : num 1.8 3.2 2.8 2.8 3.5 2.2 3.8 5.7 3.8 4.9 ...
 $ Horsepower   : int 140 200 172 172 208 110 170 180 170 200 ...
 $ RPM         : int 6300 5500 5500 5500 5700 5200 4800 4000 4800 4100 ...
 $ ERM         : int 2890 2335 2280 2535 2545 2565 1570 1320 1690 1510 ...
 $ ManualTrans  : Factor w/ 2 levels "No","Yes": 2 2 2 2 2 1 1 1 1 1 ...
 $ FuelTankCapacity: num 13.2 18 16.9 21.1 21.1 16.4 18 23 18.8 18 ...
 $ Passengers   : int 5 5 5 6 4 6 6 6 5 6 ...
 $ Length      : int 177 195 180 193 186 189 200 216 198 206 ...
 $ WheelBase   : int 102 115 102 106 109 105 111 116 108 114 ...
 $ width       : int 68 71 67 70 69 69 74 78 73 73 ...
 $ U_turn      : int 37 38 37 37 39 41 42 45 41 43 ...
 $ Rear_seat   : num 26.5 30 28 31 27 28 30.5 30.5 26.5 35 ...
 $ LuggageCapa : int 11 15 14 17 13 16 17 21 14 18 ...
 $ weight      : int 2705 3560 3375 3405 3640 2880 3470 4105 3495 3620 ...
 $ Domestic    : Factor w/ 2 levels "Non-U.S. manufacturer",...: 1 1 1 1 1 2 2 2 2 ...
 $ TotalAvgMPG : num 28 21.5 23 22.5 26 26.5 23.5 20.5 23 20.5 ...
```

Εικόνα 0.2 Οι μεταβλητές με τους τύπους δεδομένων τους μετά την προεπεξεργασία των δεδομένων

4 Περιγραφική Στατιστική

Script: 02_Univariate_Analysis.R


Σε αυτό το στάδιο της ανάλυσης, εξετάσαμε την κατανομή και τα χαρακτηριστικά κάθε μίας από τις 27 μεταβλητές του συνόλου δεδομένων ξεχωριστά. Για την καλύτερη οργάνωση και ερμηνεία των αποτελεσμάτων, ομαδοποιήσαμε τις μεταβλητές σε 8 θεματικές ενότητες (clusters).

Cluster 1: Identification & Classification

Μεταβλητές: Manufacturer, Model, Type, Domestic

(Domestic) Η σύνθεση της αγοράς στο δείγμα μας εμφανίζεται εξαιρετικά ισορροπημένη μεταξύ εγχώριων (USA) και ξένων (non-USA) κατασκευαστών (48 εγχωρίων έναντι 45 ξένων).


(Type) Ως προς τον τύπο του οχήματος (Type), η αγορά κυριαρχείται από τις κατηγορίες **Midsize** και **Small** οχημάτων, τα οποία αθροιστικά αποτελούν το ~46% του δείγματος. Αντιθέτως, τα **Vans** και τα **Large** αυτοκίνητα αποτελούν τα μικρότερα τμήματα του δείγματος.



Εικόνα 0.1 Bar plots των μεταβλητών Type και Domestic

(Model) Η μεταβλητή λειτουργεί ως μοναδικό αναγνωριστικό (Unique Identifier). Η πληθικότητα (cardinality) της είναι 93, ταυτιζόμενη ακριβώς με το μέγεθος του δείγματος (n=93). Συνεπώς, δεν απαιτείται οπτικοποίηση, καθώς η συχνότητα κάθε τιμής είναι 1.

(Manufacturer) Τέλος, όσον αφορά την κατανομή των κατασκευαστών, παρατηρείται έντονη ανισορροπία στην κατανομή των οχημάτων. Ενώ εταιρείες όπως η Ford και η Chevrolet



Εικόνα 0.2 Bar plot της μεταβλητής Manufacturer

κυριαρχούν σε πλήθος μοντέλων, πολλοί κατασκευαστές (π.χ. Saab, Infiniti) αντιπροσωπεύονται από μία μόνο παρατήρηση ($n=1$), γεγονός που περιορίζει τη δυνατότητα εκτέλεσης επαγωγικής στατιστικής (π.χ. ANOVA) σε επίπεδο μάρκας, καθώς είναι αδύνατος ο υπολογισμός της διακύμανσης εντός της ομάδας (within-group variance).

Cluster 2: Price Analysis


Μεταβλητές: MinimumPrice, MidrangePrice, MaximumPrice (σε χιλιάδες δολάρια)

Αρχικά, πραγματοποιήθηκε Έλεγχος Ποιότητας Δεδομένων (Data Quality Check) για να επιβεβαιωθεί η αριθμητική συνέπεια των μεταβλητών. Συγκεκριμένα, ελέγχθηκε αν η μεταβλητή MidrangePrice αποτελεί πράγματι τον αριθμητικό μέσο των MinimumPrice και MaximumPrice. Η συνθήκη αυτή επαληθεύτηκε πλήρως και η ανάλυση συνεχίστηκε χωρίς να απαιτηθούν διορθώσεις στα δεδομένα.

Και οι τρεις μεταβλητές τιμών παρουσιάζουν σημαντική **Θετική Λοξότητα (Positive Skewness)**, με τη Μέση Τιμή να είναι σταθερά υψηλότερη από τη Διάμεσο. Οι δείκτες λοξότητας είναι θετικοί και για τις τρεις περιπτώσεις (1.145, 1.484 και 1.969 αντίστοιχα), υποδεικνύοντας ότι η ασυμμετρία γίνεται εντονότερη καθώς μεταβαίνουμε από την ελάχιστη (MinimumPrice) προς τη μέγιστη τιμή (MaximumPrice), με τα boxplots των τριών μεταβλητών να εμφανίζουν και τη ύπαρξη ορισμένων έκτοπων τιμών (outliers) στις μεγάλες θετικές τιμές των μεταβλητών.

Ο έλεγχος κανονικότητας **Shapiro-Wilk** απέρριψε τη μηδενική υπόθεση της κανονικότητας ($p < 0.001$) για όλες τις μεταβλητές. Το αποτέλεσμα αυτό επιβεβαιώνεται και οπτικά, καθώς η κόκκινη καμπύλη της κανονικής κατανομής (προσαρμοσμένη στη μέση τιμή και τυπική απόκλιση της εκάστοτε μεταβλητής) δεν προσαρμόζεται ικανοποιητικά στα δεδομένα. Αξιοσημείωτο είναι ότι η μεταβλητή MaximumPrice, πέραν της υψηλής λοξότητας, εμφανίζεται έντονα **Λεπτόκυρτη** (Kurtosis = $6.77 > 3$), γεγονός που επιβεβαιώνει την ύπαρξη ακραίων τιμών (outliers) οι οποίες αντιστοιχούν σε πολυτελή οχήματα.

Τέλος, ιδιαίτερο ενδιαφέρον παρουσιάζει η σταθερότητα του **Συντελεστή Μεταβλητότητας (CV)**, ο οποίος κυμαίνεται στο ~ 0.50 και για τις τρεις μεταβλητές. Το εύρημα αυτό υποδηλώνει ότι, αν και η τυπική απόκλιση της μεταβλητής MaximumPrice είναι μεγαλύτερη σε σχέση με τις άλλες δύο, η σχετική μεταβλητότητα παραμένει σταθερή ανάμεσα στις τρεις μεταβλητές.




Εικόνα 0.3 Ιστόγραμμα Πυκνοτήτων και Boxplot των Price Variables σε Linear Scale

Παρόλο που η γραμμική κλίμακα (Linear Scale) προσφέρει μια γενική επισκόπηση των δεδομένων, κρίθηκε αναγκαία η περαιτέρω διερεύνηση μέσω λογαριθμικής κλίμακας (Log Scale). Στη γραμμική απεικόνιση, οι υψηλές τιμές κυριαρχούν στη μορφή της κατανομής, καθιστώντας δυσδιάκριτη τη δομή στις χαμηλότερες, "τυπικές" τιμές και δίνοντας την εικόνα μιας κατανομής που απέχει σημαντικά από την κανονική.

Με τη χρήση της λογαριθμικής κλίμακας, η εκτεταμένη δεξιά ουρά συμπύσσεται και οι τιμές κατανέμονται πιο ομοιόμορφα, οδηγώντας σε πιο συμμετρικές, καμπανοειδείς (bell-shaped) κατανομές. Αυτό συμβαίνει διότι ο λογάριθμος περιορίζει την κυριαρχία των ακραίων τιμών και διαχειρίζεται αποτελεσματικότερα την πολλαπλασιαστική μεταβλητότητα (multiplicative variability), η οποία είναι χαρακτηριστική στα οικονομικά δεδομένα. Ουσιαστικά, αποκαλύπτεται ότι οι τιμές ακολουθούν λογαριθμοκανονική (log-normal) κατανομή.

Αντίστοιχη βελτίωση παρατηρείται και στα θηκογράμματα (boxplots), όπου τα κουτιά γίνονται πιο ισορροπημένα και η διάμεσος εμφανίζεται πιο κεντρικά. Οι έκτοπες τιμές (outliers) μειώνονται φαινομενικά, καθώς πλέον αξιολογούνται βάσει της σχετικής κλίμακας και όχι του



Εικόνα 0.4 Ιστόγραμμα Πυκνοτήτων και Boxplot των Price Variables σε Log Scale

απόλυτου μεγέθους. Είναι σημαντικό να τονιστεί ότι τα δεδομένα παρέμειναν τα ίδια· αυτό που άλλαξε είναι ο τρόπος μέτρησης και απεικόνισης των διαφορών τους.


Cluster 3: Fuel Efficiency

Μεταβλητές: CityMPG, HighwayMPG, TotalAvgMPG

Αρχικά, πραγματοποιήθηκε Έλεγχος Ποιότητας Δεδομένων (Data Quality Check) για να επιβεβαιωθεί η αριθμητική συνέπεια των μεταβλητών. Συγκεκριμένα, ελέγχθηκε αν η μεταβλητή TotalAvgMPG αποτελεί πράγματι τον αριθμητικό μέσο των CityMPG και HighwayMPG. Η συνθήκη αυτή επαληθεύτηκε πλήρως και η ανάλυση συνεχίστηκε χωρίς να απαιτηθούν διορθώσεις στα δεδομένα.


Παρατηρείται, μια σαφής και συστηματική διαφορά στην κεντρική τάση, με το τυπικό αυτοκίνητο να διανύει 7 μίλια περισσότερα ανά γαλόνι στον αυτοκινητόδρομο (Διάμεσος: 28) συγκριτικά με την πόλη (Διάμεσος: 21). Παράλληλα, η οδήγηση σε συνθήκες πόλης παρουσιάζει μεγαλύτερη σχετική διασπορά ($CV=0.25$) έναντι του αυτοκινητοδρόμου ($CV=0.18$), εύρημα που υποδηλώνει ότι οι τεχνικές προδιαγραφές και ο σχεδιασμός του κινητήρα ασκούν εντονότερη επίδραση στην κατανάλωση όταν το όχημα κινείται σε αστικό περιβάλλον.

Ακόμη, η συσχέτιση μεταξύ των δύο μεταβλητών είναι εξαιρετικά ισχυρή (~ 0.94), ενώ το στενό διάστημα εμπιστοσύνης (95%) που απεικονίζεται στο διάγραμμα επιβεβαιώνει την ύπαρξη μιας σταθερής γραμμικής σχέσης. Αυτό εγείρει ανησυχίες για **πολυσυγγραμμικότητα (multicollinearity)** εάν και οι δύο μεταβλητές συμπεριληφθούν ως προβλεπτικοί παράγοντες στο ίδιο μοντέλο.



Εικόνα 0.6 Correlation City με Highway MPG

Τέλος, από την ανάλυση των ακραίων τιμών (outliers) εντοπίστηκαν 3 περιπτώσεις στην κατανάλωση πόλης και 4 στον αυτοκινητόδρομο, με τρία συγκεκριμένα μοντέλα (Geo Metro, Honda Civic, Suzuki Swift) να διακρίνονται ως εξαιρετικά αποδοτικά και στις δύο συνθήκες οδήγησης.



Εικόνα 0.5 Boxplots των τριών μεταβλητών κατανάλωσης

Cluster 4: Engine & Powertrain


Μεταβλητές: NumberOfCylinders, EngineSize, Horsepower, RPM, ERM

Η επικρατούσα τιμή (mode) στους κυλίνδρους είναι οι **4 κύλινδροι**, ενώ με διαφορά 18 μονάδων ακολουθεί η κατηγορία των οχημάτων με 6 κυλίνδρους. Τα οχήματα που έχουν 3, 5 και 8 κυλίνδρους αποτελούν ένα πολύ μικρό υποσύνολο του δείγματος, με την παρουσία της κατηγορίας **"rotary"** (για το Mazda RX-7 που δεν έχει κυλίνδρους καθόλου) είναι εμφανής ως ξεχωριστό επίπεδο, όπως ορίστηκε στο στάδιο της προ επεξεργασίας των δεδομένων.

Αναφορικά με τον κυβισμό (EngineSize) των οχημάτων παρατηρούμε μία ξεκάθαρη κορυφή στο ιστόγραμμα της μεταβλητής περίπου στα 2.5 λίτρα, όπως επίσης και μια θετική λοξότητα.

Από το ιστόγραμμα της μεταβλητής της ιπποδύναμης (Horsepower), υποψιαζόμαστε την επίδραση μίας μεταβλητής που διαφοροποιεί τα δεδομένα σε δύο διαφορετικούς πληθυσμούς καθώς αυτή εμφανίζει πολλές κορυφές (multimodel). Πιθανώς λόγω των sport οχημάτων έχουμε και λίγες πειραματικές μονάδες που διαφέρουν έντονα σε σχέση με τις υπόλοιπες (έκτοπες παρατηρήσεις).

Στο ιστόγραμμα της μεταβλητής RPM υπάρχει ομοιομορφία στην κατανομή της μεταβλητότητας γύρω από τη μέση τιμή (5200 στροφές ανά λεπτό). Στην μεταβλητή ERM επίσης παρατηρείται μία ομοιομορφία στην κατανομή της αλλά με μία κορυφή που κυμαίνεται ανάμεσα στον mean και στο 3rd Quantile.




Εικόνα 0.7 Ιστόγραμμα των μεταβλητών που αφορούν τα χαρακτηριστικά του κινητήρα του οχήματος

Cluster 5: Transmission & Drivetrain

Μεταβλητές: DriveTrainType, ManualTrans

Η μπροστινή κίνηση (**Front-Wheel Drive - FWD**) αποτελεί την τυπική διαμόρφωση (~72% του δείγματος). Η πίσω κίνηση (RWD) περιορίζεται κυρίως σε σπορ και πολυτελή οχήματα (~17%), ενώ η τετρακίνηση (4WD) με σχετική συχνότητα (~11%) παραμένει σπάνια.

Ενδιαφέρον παρουσιάζει η διαθεσιμότητα του χειροκίνητου κιβωτίου (ManualTrans), η οποία είναι εκπληκτικά υψηλή (Yes: 61, No: 32). Αυτό υποδηλώνει ότι το 1993, τα αυτόματα κιβώτια δεν είχαν εδραιωθεί στην Αμερική όπως συμβαίνει σήμερα.




Εικόνα 0.8 Bar plot των μεταβλητών DrivetrainType και ManualTrans

Cluster 6: Safety Features

Μεταβλητές: AirBags

Τα δεδομένα αποτυπώνουν μια αγορά σε μετάβαση όσον αφορά την ασφάλεια:

- **Driver Only:** Η πιο κοινή διαμόρφωση (~46%).
- **None:** Απουσία αερόσακων σε σημαντικό ποσοστό (~36%).
- **Driver & Passenger:** Πολυτελές χαρακτηριστικό που συναντάται μόνο στο ~17% του δείγματος.




Εικόνα 0.9 Κατανομή της μεταβλητής AirBags

Cluster 7: Size & Dimensions

Μεταβλητές: Length, Width, WheelBase, U_turn, Weight

Σε αντίθεση με τα Price Variables και τις μεταβλητές Horsepower και EngineSize, οι φυσικές διαστάσεις (Length, Width, Weight) παρουσιάζουν κατά προσέγγιση **Κανονικές Κατανομές**. Αυτό υποδηλώνει τυποποιημένους κατασκευαστικούς περιορισμούς και σαφώς καθορισμένες κατηγορίες οχημάτων. Αναμένουμε εξαιρετικά υψηλή πολυσυγγραμμικότητα μεταξύ αυτών των μεταβλητών (π.χ. τα μακρύτερα αυτοκίνητα είναι σχεδόν πάντα βαρύτερα και φαρδύτερα).




Εικόνα 0.10 Ιστογράμματα των μεταβλητών που σχετίζονται με το μέγεθος των οχημάτων

Cluster 8: Interior Space & Capacity

Μεταβλητές: Passengers, Rear_seat, LuggageCapa, FuelTankCapacity

Η μεταβλητή Passengers είναι διακριτή με κυρίαρχη τιμή τα **5 άτομα**. Παρατηρούμε ότι υπάρχουν μόνο δύο διαθέσιμα και μόνο ένα 8-θέσιο όχημα (βαν), ενώ η μεταβλητή Rear_seat είναι αρκετά συμπαγής γύρω από τη μέση τιμή.

Η μεταβλητή LuggageCapa εμφανίζει αριστερή λοξότητα. Η συμπλήρωση (imputation) που πραγματοποιήθηκε στο προηγούμενο στάδιο για τον χώρο αποσκευών των Vans, διασφαλίζει ότι αυτά τα οχήματα δεν εμφανίζονται με "μηδενικό" χώρο, διατηρώντας τη χρησιμότητα της μεταβλητής για την ανάλυση. Αυτή η μεταβλητή όπως και η μεταβλητή FuelTankCapacity φαίνεται να επηρεάζονται από την επίδραση και άλλων μεταβλητών.



Εικόνα 0.1 Ιστόγραμμα μεταβλητών που σχετίζονται με το capacity και τους εσωτερικούς χώρους

5 Στατιστική Συμπερασματολογία

Περνώντας πλέον στη Στατιστική Συμπερασματολογία, η εστίασή μας μετατοπίζεται από την περιγραφή μεμονωμένων μεταβλητών στη διερεύνηση σχέσεων μεταξύ τους και στον έλεγχο ερευνητικών υποθέσεων.

Research Question 1


Script: 03_Bivariate_Analysis.R

Το πρώτο ερώτημα που εξετάστηκε αφορά τη σχέση μεταξύ μιας ποσοτικής και μιας κατηγορικής μεταβλητής δύο επιπέδων, και συγκεκριμένα: «Υπάρχει στατιστικά σημαντική διαφορά τιμής μεταξύ Εγχώριων (USA) και Ξένων (non-USA) αυτοκινήτων;». Για τον σκοπό αυτό, χρησιμοποιήθηκε η MidrangePrice ως αντιπροσωπευτική τιμή και η μεταβλητή Domestic για την ομαδοποίηση.

Η μεθοδολογική προσέγγιση ξεκίνησε με τον έλεγχο των απαραίτητων προϋποθέσεων. Αρχικά, διαπιστώθηκε ότι τα μεγέθη των δειγμάτων $n_{USA} = 48$ και $n_{non-USA} = 45$ υπερβαίνουν αμφότερα το όριο των 30 παρατηρήσεων. Βάσει του Κεντρικού Οριακού Θεωρήματος (CLT), αυτό εξασφαλίζει ότι η δειγματική κατανομή των μέσων προσεγγίζει την κανονική, επιτρέποντας τη χρήση παραμετρικών ελέγχων ανεξαρτήτως της κανονικότητας των πρωτογενών δεδομένων. Στη συνέχεια, διενεργήθηκε έλεγχος F (F-test) για την ισότητα των διακυμάνσεων $H_0: \sigma_{USA}^2 = \sigma_{non-USA}^2$. Το αποτέλεσμα του ελέγχου ($p\text{-value} = 0.01387 < 0.05$) οδήγησε στην απόρριψη της υπόθεσης περί ισότητας των διακυμάνσεων. Συνεπώς, για τον έλεγχο της ισότητας των μέσων ($H_0: \mu_{USA} = \mu_{non-USA}$), επιλέχθηκε το **Welch's t-test**, το οποίο δεν προϋποθέτει ομοσκεδαστικότητα.

Τα αποτελέσματα του ελέγχου Welch t-test ($t = 0.954, p\text{-value} = 0.3428$) κατέδειξαν ότι **δεν υπάρχει στατιστικά σημαντική διαφορά** στις μέσες τιμές μεταξύ εγχώριων και ξένων αυτοκινήτων, καθώς το $p\text{-value}$ υπερβαίνει το επίπεδο σημαντικότητας $\alpha = 0.05$. Το συμπέρασμα αυτό ενισχύεται από το 95% Διάστημα Εμπιστοσύνης $[-2.10, 5.97]$, το οποίο περιλαμβάνει την τιμή μηδέν, υποδεικνύοντας ότι η διαφορά των μέσων θα μπορούσε εύλογα να είναι μηδενική. Παρόλο που η δειγματική μέση τιμή των ξένων αυτοκινήτων εμφανίζεται

ελαφρώς υψηλότερη (~ \$20,509 έναντι ~ \$18,573), η διαφορά αυτή αποδίδεται σε τυχαία δειγματοληπτική διακύμανση και όχι σε πραγματική διαφοροποίηση στους πληθυσμούς. Αυτό μπορεί κανείς να το επιβεβαιώσει και από το παρακάτω boxplot.




Εικόνα 0.2 Κατανομή της Midrange Price μεταβλητής ως προς τη μεταβλητή Domestic

Research Question 2

Script: 04_ANOVA_Analysis.R

Στο πλαίσιο του δεύτερου ερευνητικού ερωτήματος, εξετάστηκε κατά πόσον υπάρχει στατιστικά σημαντική διαφορά στην απόδοση καυσίμου εντός πόλης (CityMPG) ανάλογα με τον τύπο μετάδοσης κίνησης (DriveTrainType).

Για τη διερεύνηση της υπόθεσης αυτής, επιλέχθηκε ως μεθοδολογία η **Ανάλυση Διακύμανσης Μονής Κατεύθυνσης (One-Way ANOVA)**. Η επιλογή της ANOVA ως γενίκευση του t-test είναι απαραίτητη, καθώς η ανεξάρτητη μεταβλητή (DriveTrainType) είναι κατηγορική με τρία επίπεδα (Front-wheel, Rear-wheel, All-wheel/4WD) και όχι δύο. Η μηδενική υπόθεση (H_0) που τέθηκε προς έλεγχο ορίζει ότι η μέση κατανάλωση είναι ίση σε όλες τις ομάδες ($\mu_{Front} =$



Εικόνα 0.3 Κατανομή του CitMPG ως προς τη μεταβλητή DriveTrainType

$\mu_{Rear} = \mu_{4WD}$), ενώ η εναλλακτική (H_1) υποστηρίζει ότι τουλάχιστον ένας μέσος όρος διαφοροποιείται σημαντικά. Πριν την εφαρμογή του μοντέλου, η κατανομή της απόδοσης οπτικοποιήθηκε μέσω θηκογραμμάτων (boxplots), ενώ κατά την προσαρμογή του μοντέλου (μέσω της συνάρτησης `aov()` στην R), η συνολική μεταβλητότητα διαχωρίστηκε σε μεταβλητότητα μεταξύ των ομάδων (SSA) και σε ανεξήγητη μεταβλητότητα (SSE) για τον υπολογισμό της στατιστικής F. Από το boxplot δεν φαίνεται να υπάρχει κάποια διαφορά αλλά για να είμαστε σίγουροι πρέπει να το ελέγξουμε εφαρμόζοντας ένα στατιστικό έλεγχο.

Τα αποτελέσματα της Ανάλυσης Διακύμανσης ανέδειξαν τιμή $F = 5.982$ και $p\text{-value} = 0.00364$. Καθώς η τιμή p είναι μικρότερη από το επίπεδο σημαντικότητας $\alpha = 0.05$, η μηδενική υπόθεση απορρίπτεται, οδηγώντας στο συμπέρασμα ότι ο τύπος μετάδοσης ασκεί στατιστικά σημαντική επίδραση στην κατανάλωση του καυσίμου σε αστική περιοχή.

Δεδομένης της στατιστικής σημαντικότητας, ακολούθησε μετα-ανάλυση (post-hoc) με τη μέθοδο Tukey's HSD. Το βήμα αυτό ήταν απαραίτητο για τον ακριβή εντοπισμό των ζευγών που διαφέρουν, αποφεύγοντας την αύξηση του σφάλματος τύπου I που θα προέκυπτε από πολλαπλά t-tests. Από τις κατά ζεύγη συγκρίσεις, προέκυψε ότι η μόνη στατιστικά σημαντική διαφορά ($p = 0.0045$) εντοπίζεται μεταξύ των οχημάτων με πίσω κίνηση (Rear-wheel) και αυτών με μπροστινή κίνηση (Front-wheel). Συγκεκριμένα, τα μπροστινοκίνητα οχήματα εμφανίζονται σημαντικά πιο αποδοτικά, διανύοντας κατά μέσο όρο 4.83 μίλια περισσότερα ανά γαλόνι σε σχέση με τα πισωκίνητα. Αντίθετα, οι συγκρίσεις που αφορούσαν την τετρακίνηση (4WD) δεν έδειξαν στατιστικά σημαντικές διαφορές ($p > 0.05$), τοποθετώντας τα οχήματα αυτά σε ενδιάμεσο επίπεδο απόδοσης χωρίς σαφή διαφοροποίηση από τις άλλες δύο κατηγορίες στο παρόν δείγμα.


Research Question 3

Script: 05_Chi_Square_Analysis.R

Στο πλαίσιο του τρίτου ερευνητικού ερωτήματος, διερευνήθηκε η ύπαρξη συσχέτισης μεταξύ της προέλευσης του οχήματος (Origin: Domestic vs. Non-US) και της διαθεσιμότητας αερόσακων (AirBags: None, Driver only, Driver & Passenger). Για την ανάλυση της σχέσης μεταξύ των δύο αυτών κατηγορικών μεταβλητών, κατασκευάστηκε αρχικά ένας Πίνακας Συνάφειας (Contingency Table) για την παρατήρηση της κατανομής συχνοτήτων, ενώ η οπτικοποίηση των αναλογιών εντός κάθε ομάδας προέλευσης πραγματοποιήθηκε μέσω Ραβδογράμματος Σωρευτικής Συχνότητας (Stacked Bar Plot). Από αυτή την αρχική ανάλυση δεν φαίνεται να υπάρχει εξάρτηση μεταξύ των δύο αυτών μεταβλητών.

	Non-U.S. manufacturer	U.S. manufacturer
none	16.45	17.55
driver only	20.81	22.19
driver & passenger	7.74	8.26

Εικόνα 0.4 Πίνακας Συνάφειας (Contingency Table) για τις δύο μεταβλητές



Εικόνα 0.5 Stacked Bar Plot για τις δύο μεταβλητές

Ως κύριος στατιστικός έλεγχος επιλέχθηκε το Τεστ Ανεξαρτησίας χ^2 του Pearson (Pearson's Chi-Square Test), με τη Μηδενική Υπόθεση (H_0) να ορίζει ότι οι μεταβλητές είναι ανεξάρτητες, δηλαδή ότι η αναλογία των αυτοκινήτων με αερόσακους δεν εξαρτάται από την προέλευση του κατασκευαστή (εγχώριος ή ξένος). Πριν την ερμηνεία των αποτελεσμάτων, επιβεβαιώθηκε η εγκυρότητα των προϋποθέσεων του ελέγχου, καθώς όλες οι αναμενόμενες συχνότητες (expected frequencies) στον πίνακα συνάφειας βρέθηκαν μεγαλύτερες του 5 (με ελάχιστη τιμή 7.74). Επιπροσθέτως, για λόγους εγκυρότητας (robustness check), διενεργήθηκε και το Fisher's Exact Test, το οποίο παραμένει αξιόπιστο ακόμη και σε περιπτώσεις μικρών δειγμάτων.


Τα αποτελέσματα της ανάλυσης ($\chi^2 = 0.48, df = 2, p\text{-value} = 0.7864$) οδήγησαν στη μη απόρριψη της Μηδενικής Υπόθεσης, καθώς η τιμή p υπερβαίνει σημαντικά το επίπεδο σημαντικότητας $\alpha = 0.05$. Συνεπώς, δεν προκύπτει στατιστικά σημαντική συσχέτιση μεταξύ της προέλευσης του κατασκευαστή και της διαθεσιμότητας αερόσακων. Το συμπέρασμα αυτό επιβεβαιώθηκε πλήρως και από το Fisher's Exact Test ($p\text{-value} = 0.8223$). Τα ευρήματα υποδεικνύουν ότι οι μικρές διαφορές που παρατηρήθηκαν στα πρωτογενή δεδομένα οφείλονται σε τυχαία δειγματοληπτική διακύμανση και όχι σε συστηματική διαφορά στα πρότυπα ασφαλείας μεταξύ των αμερικανικών και των ξένων αυτοκινητοβιομηχανιών κατά το έτος 1993.

Research Question 4

Script: 06_Correlation_Analysis.R

Στο πλαίσιο του τέταρτου ερευνητικού ερωτήματος, διερευνήθηκε η ύπαρξη σημαντικής γραμμικής συσχέτισης ανάμεσα σε δύο ποσοτικές μεταβλητές: την Ιπποδύναμη (Horsepower) και την Αποδοτικότητα Καυσίμου στον Αυτοκινητόδρομο (HighwayMPG). Η μεθοδολογική προσέγγιση περιλάμβανε αρχικά την οπτική επισκόπηση των δεδομένων μέσω διαγράμματος διασποράς (scatterplot), με την Ιπποδύναμη στον άξονα x και την Κατανάλωση στον άξονα y . Η διαδικασία αυτή επέτρεψε τον έλεγχο της μορφής (γραμμική έναντι μη γραμμικής), της κατεύθυνσης της σχέσης, καθώς και τον εντοπισμό πιθανών έκτοπων τιμών.

Στη συνέχεια, ποσοτικοποιήθηκε η ένταση και η κατεύθυνση της γραμμικής συσχέτισης μέσω του υπολογισμού του συντελεστή συσχέτισης του Pearson (r), ελέγχοντας την ερευνητική υπόθεση ότι ο συντελεστής στον πληθυσμό είναι διάφορος του μηδενός ($H_1: \rho \neq 0$).



Εικόνα 0.6 Scatter plot που δείχνει την αρνητική συσχέτιση των δύο μεταβλητών

Η ανάλυση ανέδειξε συντελεστή συσχέτισης Pearson ίσο με $r = -0.622$. Το αρνητικό πρόσημο υποδηλώνει σαφώς μια αρνητική συσχέτιση: καθώς αυξάνεται η ιπποδύναμη, η αποδοτικότητα καυσίμου στον αυτοκινητόδρομο τείνει να μειώνεται. Το μέγεθος του συντελεστή ($|0.62|$) υποδεικνύει μια μέτρια προς ισχυρή γραμμική συσχέτιση μεταξύ ισχύος και οικονομίας. Ο στατιστικός έλεγχος παράγαγε τιμή t-statistic ίση με -7.59 και p-value της τάξης του 2.7×10^{-11} ($p < 0.001$). Δεδομένου ότι η τιμή p είναι πολύ μικρότερη από το επίπεδο σημαντικότητας $\alpha = 0.05$, η μηδενική υπόθεση απορρίπτεται, επιβεβαιώνοντας ότι η συσχέτιση είναι στατιστικά σημαντική.

Το συμπέρασμα αυτό θωρακίζεται περαιτέρω από το 95% Διάστημα Εμπιστοσύνης $[-0.733, -0.480]$, αφού το μηδέν δεν εμπεριέχεται. Το γεγονός ότι το διάστημα αυτό δεν περιλαμβάνει την τιμή μηδέν, μας επιτρέπει να δηλώσουμε με 95% βεβαιότητα ότι στον ευρύτερο πληθυσμό των αυτοκινήτων της εποχής, η πραγματική συσχέτιση κυμαίνεται μεταξύ -0.73 και -0.48 . Συνοψίζοντας, τα δεδομένα τεκμηριώνουν μια στατιστικά σημαντική, μέτριας προς ισχυρή έντασης αρνητική σχέση, όπου οι ισχυρότεροι κινητήρες συνδέονται συστηματικά με χαμηλότερη οικονομία καυσίμου.


Research Question 5

Script: 07_ANCOVA.R

Στο πλαίσιο του πέμπτου ερευνητικού ερωτήματος, εξετάστηκε κατά πόσον ο Τύπος του αυτοκινήτου (Type) επηρεάζει την αποδοτικότητα καυσίμου στον αυτοκινητόδρομο (HighwayMPG), όταν ελέγχουμε την επίδραση της Ιπποδύναμης (Horsepower). Η μεθοδολογία που επιλέχθηκε είναι η Ανάλυση Συνδιακύμανσης (ANCOVA). Στο μοντέλο αυτό, η HighwayMPG ορίστηκε ως η εξαρτημένη ποσοτική μεταβλητή, ο Type ως ο κατηγορικός παράγοντας (με 6 επίπεδα: Small, Sporty, Compact, Midsize, Large, Van) και η Horsepower ως η ποσοτική συμμεταβλητή (covariate). Σημειώνεται ότι, παρόλο που η HighwayMPG είναι διακριτή μεταβλητή (ακέραιοι αριθμοί), το εύρος τιμών της θεωρείται

επαρκές για να αντιμετωπιστεί ως συνεχής, επιτρέποντας την εφαρμογή του Γενικού Γραμμικού Μοντέλου υπό την παραδοχή της κανονικότητας των καταλοίπων.

Η ανάλυση ξεκίνησε με τον έλεγχο της βασικής προϋπόθεσης της ANCOVA, δηλαδή της Ομοιογένειας των Κλίσεων (Homogeneity of Slopes). Μέσω της οπτικής επισκόπησης του διαγράμματος διασποράς, παρατηρήθηκε ότι οι ευθείες παλινδρόμησης για τους διαφορετικούς τύπους οχημάτων δεν είναι παράλληλες (τέμνονται ή αποκλίνουν), γεγονός που αποτελεί ένδειξη αλληλεπίδρασης. Η στατιστική επιβεβαίωση προήλθε από την προσαρμογή ενός μοντέλου που περιλάμβανε τον όρο αλληλεπίδρασης (Horsepower * Type). Τα αποτελέσματα ($F = 2.708$, $p\text{-value} = 0.0259$) οδήγησαν στην απόρριψη της μηδενικής υπόθεσης περί ισότητας των κλίσεων, καθώς η τιμή p είναι μικρότερη του 0.05.



Εικόνα 0.7 Διάγραμμα διασποράς με ευθείες παλινδρόμησης ως προς τον τύπο του οχήματος

Το εύρημα αυτό υποδηλώνει ότι η σχέση μεταξύ ισχύος και κατανάλωσης δεν είναι ενιαία για όλες τις κατηγορίες οχημάτων. Για παράδειγμα, η αύξηση της ιπποδύναμης μπορεί να επιβαρύνει δυσανάλογα την κατανάλωση σε ένα μικρό αυτοκίνητο σε σχέση με ένα μεγάλο. Αυστηρά μιλώντας, η παραβίαση της παραδοχής των παραλλήλων κλίσεων επιβάλλει προσοχή στην ερμηνεία των διαφορών μεταξύ των ομάδων.

Ωστόσο, εξετάζοντας τις Κύριες Επιδράσεις (Main Effects) παρά την αλληλεπίδραση, προκύπτουν σημαντικά συμπεράσματα. Η ιπποδύναμη παραμένει ισχυρός προβλεπτικός παράγοντας ($F = 100.41$, $p < 0.001$). Το σημαντικότερο είναι ότι, ακόμη και μετά τον έλεγχο της ισχύος, ο Τύπος του οχήματος παραμένει εξαιρετικά σημαντικός ($F = 14.54$, $p < 0.001$). Αυτό αποδεικνύει ότι τα δομικά χαρακτηριστικά (αεροδυναμική, βάρος, σύστημα μετάδοσης) που σχετίζονται με τον τύπο του οχήματος επηρεάζουν την οικονομία καυσίμου πέρα από την καθαρή ισχύ του κινητήρα. Συμπερασματικά, αν και η ιπποδύναμη είναι καθοριστική, ο τύπος του αυτοκινήτου παίζει σημαντικό ρόλο, με τη σχέση τους να είναι σύνθετη και μεταβαλλόμενη ανάλογα με την κατηγορία του οχήματος.

Research Question 6

Script: 08_ONEWAY_ANOVA_MaxPrice_AirBags.R

Στο πλαίσιο του έκτου ερευνητικού ερωτήματος, εξετάστηκε κατά πόσον υπάρχει στατιστικά σημαντική διαφορά στη Μέγιστη Τιμή (MaximumPrice) του αυτοκινήτου ανάλογα με τον εγκατεστημένο εξοπλισμό αερόσακων (AirBags). Για τον σκοπό αυτό, εφαρμόστηκε Ανάλυση


Διακύμανσης Μονής Κατεύθυνσης (One-Way ANOVA). Η MaximumPrice ορίστηκε ως η εξαρτημένη ποσοτική μεταβλητή, ενώ ο παράγοντας AirBags (με επίπεδα: None, Driver only, Driver & Passenger) οργανώθηκε σε ιεραρχική σειρά ώστε να αντικατοπτρίζει την αυξανόμενη πολυπλοκότητα των συστημάτων ασφαλείας. Η Μηδενική Υπόθεση (H_0) έλεγξε την ισότητα της μέσης Μέγιστης Τιμής σε όλες τις κατηγορίες εξοπλισμού.

Η ανάλυση ξεκίνησε με την οπτικοποίηση των κατανομών τιμών μέσω θηκογραμμάτων (boxplots) και ακολούθησε η προσαρμογή του μοντέλου ANOVA. Τα αποτελέσματα ήταν εξαιρετικά σημαντικά, με τιμή $F = 20.15$ και $p\text{-value} < 0.001$. Το γεγονός ότι η τιμή p είναι πρακτικά μηδενική οδήγησε στην ισχυρή απόρριψη της μηδενικής υπόθεσης, επιβεβαιώνοντας ότι η παρουσία και ο τύπος των αερόσακων αποτελούν ισχυρούς δείκτες της κατηγορίας τιμής του οχήματος.

Λόγω της στατιστικής σημαντικότητας, διενεργήθηκε έλεγχος πολλαπλών συγκρίσεων **Tukey's HSD**, ο οποίος αποκάλυψε μια σαφή, θετική "κλιμακωτή" σχέση (stepwise relationship) μεταξύ ασφάλειας και τιμής. Συγκεκριμένα:

- Η μετάβαση από την απουσία αερόσακων σε αερόσακο οδηγού ("Driver Only" vs. "None") συνοδεύεται από μια μέση αύξηση τιμής της τάξης των **\$8,904** ($p = 0.00019$).
- Η μετάβαση από τον αερόσακο οδηγού σε διπλούς αερόσακους ("Driver & Passenger" vs. "Driver Only") επιφέρει μια επιπλέον σημαντική αύξηση περίπου **\$8,223** ($p = 0.00888$).
- Συνολικά, τα αυτοκίνητα με διπλούς αερόσακους είναι κατά μέσο όρο **\$17,127** ακριβότερα από εκείνα χωρίς αερόσακους ($p < 0.00001$).

Συμπερασματικά, η ανάλυση επιβεβαιώνει ότι το 1993 οι αερόσακοι δεν αποτελούσαν απλώς βασικό εξοπλισμό αλλά premium χαρακτηριστικό. Τα δεδομένα υποδεικνύουν μια διακριτή ιεραρχία τιμών: τα βασικά/οικονομικά μοντέλα δεν διέθεταν αερόσακους, τα μεσαία κατηγορίας διέθεταν αερόσακο οδηγού, ενώ τα πολυτελή/high-end μοντέλα ξεχώριζαν με την παρουσία διπλών αερόσακων.




Εικόνα 0.8 Κατανομή MaximumPrice ως προς Airbag Type


6 Ανάλυση Παλινδρόμησης

6.1 Παλινδρόμηση στην Ελάχιστη Τιμή Οχήματος

Στόχος της παρούσας ενότητας είναι η ανάπτυξη και αξιολόγηση ενός μοντέλου Πολλαπλής Γραμμικής Παλινδρόμησης για την πρόβλεψη της ελάχιστης τιμής (MinimumPrice) των οχημάτων. Η διαδικασία που ακολουθήθηκε περιλάμβανε τον μετασχηματισμό των δεδομένων, την αυστηρή επιλογή μεταβλητών και τον έλεγχο των διαγνωστικών υποθέσεων. Αρχικά, λόγω της σημαντικής θετικής λοξότητας που παρουσίαζε η εξαρτημένη μεταβλητή, κρίθηκε απαραίτητος ο λογαριθμικός μετασχηματισμός της ($\log(\text{MinimumPrice})$). Η ενέργεια αυτή οδήγησε σε μια πιο συμμετρική, καμπανοειδή κατανομή, ικανοποιώντας την υπόθεση κανονικότητας που απαιτεί η μέθοδος των Ελαχίστων Τετραγώνων (OLS).




Εικόνα 0.2 Κατανομή του MinimumPrice πριν τον μετασχηματισμό



Εικόνα 0.1 Κατανομή του MinimumPrice μετά τον μετασχηματισμό

Για την αποφυγή υπερπροσαρμογής (overfitting) που θα προέκυπτε από τη συμπερίληψη και των 27 μεταβλητών και των αλληλεπιδράσεων 2^{ης} τάξης, υιοθετήθηκε μια υβριδική στρατηγική επιλογής χαρακτηριστικών. Σε πρώτο στάδιο, προσαρμόστηκε ένα Δέντρο Παλινδρόμησης (Regression Tree), το οποίο ανέδειξε ως κυριότερους προβλεπτικούς παράγοντες τις μεταβλητές Horsepower, CityMPG, Type, Weight και LuggageCapa. Στη συνέχεια, εφαρμόστηκε Βηματική Παλινδρόμηση (Stepwise Regression) με κριτήριο βελτιστοποίησης AIC στο σύνολο εκπαίδευσης (70% των δεδομένων), επιτρέποντας στον αλγόριθμο να διατηρήσει στο τελικό μοντέλο μόνο τις στατιστικά σημαντικές μεταβλητές.



Εικόνα 0.3 Δενδρόγραμμα για την μεταβλητή MinimuPrice

Το τελικό μοντέλο που προέκυψε χαρακτηρίζεται από υψηλή προσαρμογή, με τον συντελεστή προσδιορισμού (R^2) να ανέρχεται στο 0.8234. Αυτό σημαίνει ότι το μοντέλο ερμηνεύει το 82.3% της συνολικής διακύμανσης της τιμής, ενώ το $p < 0.001$ επιβεβαιώνει τη συνολική στατιστική σημαντικότητα του μοντέλου. Αναφορικά με τους συντελεστές, ο τύπος του οχήματος (Type) και το βάρος (Weight) αναδείχθηκαν ως σημαντικοί παράγοντες. Συγκεκριμένα, τα οχήματα τύπου Van εμφανίζονται σημαντικά φθηνότερα (συντελεστής -

```
> print(summary(final_model))
```

```
Call:
lm(formula = log_Price ~ Horsepower + CityMPG + Type + Weight +
    LuggageCapa, data = train_data)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-0.46187 -0.11344 -0.02265  0.12719  0.58524
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.9146896  0.5533190   3.460  0.00105 **
Horsepower    0.0023747  0.0013754   1.727  0.08987 .
CityMPG      -0.0160324  0.0109308  -1.467  0.14815
TypeLarge    -0.0243895  0.1467024  -0.166  0.86857
TypeMidsize  0.1333295  0.0991002   1.345  0.18402
TypeSmall   -0.1264939  0.1206608  -1.048  0.29907
TypeSporty   -0.1926000  0.1362066  -1.414  0.16299
TypeVan      -0.3587725  0.1696352  -2.115  0.03898 *
Weight        0.0004387  0.0002003   2.191  0.03272 *
LuggageCapa  -0.0334845  0.0171987  -1.947  0.05666 .
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.2183 on 55 degrees of freedom
```

Εικόνα 0.4 Output του stepwise regression


0.359, $p=0.039$) σε σχέση με τα Compact αυτοκίνητα, όταν οι υπόλοιποι παράγοντες διατηρούνται σταθεροί. Αντίθετα, το βάρος παρουσιάζει θετική συσχέτιση (0.0004 , $p=0.032$), υποδηλώνοντας ότι τα βαρύτερα οχήματα τείνουν να είναι ακριβότερα. Αξίζει να σημειωθεί ότι η ιπποδύναμη (Horsepower), αν και διατηρήθηκε στο μοντέλο λόγω βελτίωσης του κριτηρίου AIC, δεν παρουσίασε στατιστική σημαντικότητα ($p=0.089$).

Κατά τον έλεγχο των υποθέσεων, παρατηρήθηκαν αυξημένες τιμές στον Συντελεστή Πληθωρισμού Διακύμανσης (VIF) για τις μεταβλητές Type (24.4) και Weight (18.9), επιβεβαιώνοντας την αναμενόμενη συσχέτιση μεταξύ μεγέθους και βάρους. Ωστόσο, οι μεταβλητές διατηρήθηκαν καθώς ο γενικευμένος δείκτης VIF βρέθηκε εντός αποδεκτών ορίων.

```
[1] "--- VIF (Multicollinearity Check) ---"
      GVIF Df GVIF^(1/(2*Df))
Horsepower  6.497194  1      2.548959
CityMPG     4.687304  1      2.165018
Type        24.474176  5      1.376800
Weight      18.906860  1      4.348202
LuggageCapa  6.376855  1      2.525244
```

Εικόνα 0.5 Γενικευμένος δείκτης VIF

Ο έλεγχος κανονικότητας των καταλοίπων (Shapiro-Wilk) έδωσε τιμή $p=0.0286$, απορρίπτοντας τυπικά την υπόθεση της τέλει κανονικότητας. Η απόκλιση αυτή οφείλεται κυρίως σε λίγες ακραίες τιμές (outliers) που αφορούν πολύ ακριβά οχήματα, ωστόσο η ομοσκεδαστικότητα ικανοποιείται.



Εικόνα 0.6 Ομοσκεδαστικότητα και υπόλοιπα


Τέλος, η αξιολόγηση της προγνωστικής ικανότητας στο σύνολο ελέγχου (Test Set - 30%) έδειξε RMSE ίσο με 5.24 και MAE ίσο με 3.9 (σε χιλιάδες δολάρια). Δεδομένου του εύρους τιμών της εξαρτημένης μεταβλητής MinimumPrice κυμαίνεται στο διάστημα από \$6.7 έως \$45.4 (σε χιλιάδες δολάρια), το σφάλμα των ~\$4-5k κρίνεται αποδεκτό. Αυτή η ανάλυση παλινδρόμησης μπορεί να βρεθεί στα scripts "09_Regression_preparation_Minimum_Price.R" και "10_Regression_Analysis_Minimu_Price.R".

6.2 Παλινδρόμηση στην Κατανάλωση των οχημάτων στην πόλη

Scripts: 11_Regression_preparation_CityMPG.R και 12_regression_Citympg.R

Στο επόμενο στάδιο της ανάλυσης, διερευνήθηκαν οι παράγοντες που επηρεάζουν την κατανάλωση καυσίμου σε συνθήκες πόλης (CityMPG). Για τον σκοπό αυτό, υιοθετήθηκε η προσέγγιση των Γενικευμένων Γραμμικών Μοντέλων (GLM), κατάλληλων για δεδομένα απαρίθμησης (count data), μιας και η εξαρτημένη μεταβλητή είναι θετική και ακέραιη.

Η διαδικασία ξεκίνησε με την ταυτοποίηση της κατανομής της εξαρτημένης μεταβλητής, χρησιμοποιώντας το πακέτο `fitdistrplus` για τη σύγκριση των θεωρητικών κατανομών Poisson και Negative Binomial. Είναι σημαντικό να αναφερθεί ένας περιορισμός: οι έλεγχοι Καλής Προσαρμογής (Goodness-of-Fit tests) έδειξαν ότι καμία από τις δύο κατανομές δεν προσαρμόζεται τέλεια στα δεδομένα ($p\text{-values} < 0.05$). Ωστόσο, βάσει του Κριτηρίου Πληροφορίας Akaike (AIC), η Negative Binomial παρείχε καλύτερη προσέγγιση έναντι της Poisson και επιλέχθηκε ως η συνάρτηση σύνδεσης.




Εικόνα 0.7 Σύγκριση καλής προσαρμογής θεωρητικής κατανομής στην μεταβλητή απόκρισης

Για την επιλογή των μεταβλητών, εξαιρέθηκαν εξ αρχής οι οικονομικοί δείκτες (Τιμή), καθώς θέλαμε να εξετάσουμε πως τα φυσικά χαρακτηριστικά ενός οχήματος επηρεάζουν την κατανάλωση τους και για την αποφυγή συγγραμικότητας. Μέσω εξέτασης της σχέσης διάφορων παρογόντων με την εξαρτημένη μεταβλητή αλλά και από το Δέντρο Παλινδρόμησης, αναδείχθηκαν ως αρχικοί υποψήφιοι παράγοντες το Βάρος (Weight), το Μήκος (Length), οι Στροφές ανά Μίλι (ERM), οι Κύλινδροι (Cylinders) και η Χωρητικότητα Καυσίμου (FuelTankCapacity) και ο Τύπος (Type) του οχήματος. Στη συνέχεια, εφαρμόστηκε αλγόριθμος Βηματικής Παλινδρόμησης (Stepwise Regression) με βελτιστοποίηση AIC, επιτρέποντας την αφαίρεση ή προσθήκη μεταβλητών για την εξαγωγή του βέλτιστου και πιο λιτού μοντέλου.

Κατά την προσαρμογή του μοντέλου, παρατηρήθηκε υπολογιστική αστάθεια με την εκτίμηση μιας εξαιρετικά υψηλής τιμής για την παράμετρο Θήτα ($\theta \approx 1,686,830$). Παρά την προειδοποίηση αυτή, το μοντέλο κρίνεται λειτουργικό. Η βηματική διαδικασία απλοποίησε δραστικά το αρχικό μοντέλο, διατηρώντας τελικά μόνο δύο μεταβλητές: το Βάρος (Weight, $p = 0.0059$), που αποτελεί τον μοναδικό στατιστικά σημαντικό προβλεπτικό παράγοντα, και τη

Χωρητικότητα Καυσίμου (FuelTankCapacity, $p = 0.129$), η οποία διατηρήθηκε για τη βελτιστοποίηση του AIC.



Εικόνα 0.8 Regression Tree για τη μεταβλητή CityMPG

Η ερμηνεία των συντελεστών (λόγω της λογαριθμικής συνάρτησης σύνδεσης) επιβεβαιώνει την αρνητική επίδραση του βάρους. Συγκεκριμένα, ο εκθετικός συντελεστής του βάρους είναι 0.99976, υποδεικνύοντας ότι για κάθε επιπλέον λίβρα βάρους, η αποδοτικότητα καυσίμου πολλαπλασιάζεται επί αυτόν τον παράγοντα.

Το τελικό μοντέλο παρατηρούμε ότι η απόκλιση των υπολοίπων (23.89) είναι πολύ μεγάλη σε σχέση με τους βαθμούς ελευθερίας (90) και επομένως φαίνεται ότι η υπόθεση της Negative Binomial δεν δίνει αξιόπιστα αποτελέσματα.

```

> print(summary(final_model))

Call:
glm.nb(formula = CityMPG ~ Weight + FuelTankCapacity, data = count_data,
       init.theta = 1686829.771, link = log)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  4.21172197  0.11368673  37.047 < 0.0000000000000002 ***
Weight      -0.00023777  0.00008633  -2.754   0.00589 **
FuelTankCapacity -0.02376888  0.01567934  -1.516   0.12954
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(1686830) family taken to be 1)

Null deviance: 117.953 on 92 degrees of freedom
Residual deviance: 23.891 on 90 degrees of freedom
AIC: 490.07

Number of Fisher Scoring iterations: 1

              Theta: 1686830
             Std. Err.: 31609651
Warning while fitting theta: iteration limit reached

2 x log-likelihood: -482.075
  
```

Εικόνα 0.9 Προσαρμογή glm model στη μεταβλητή CityMPG

7 Αναφορές

- [1] R. H. Lock, “1993 New Car Data,” *Journal of Statistics Education*, vol. 1, no. 1, Jul. 1993, doi: 10.1080/10691898.1993.11910459.